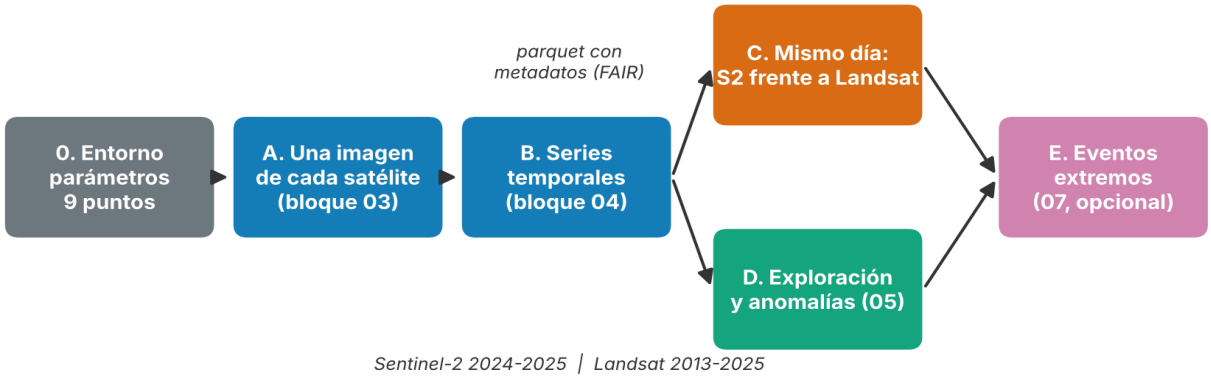
Sentinel-2 y Landsat en el Biobío medio

Resumen del notebook *comparacion_sentinel2_landsat.ipynb*: qué hace cada bloque

El notebook compara dos satélites ópticos sobre el río Biobío entre Nacimiento y aguas arriba de Negrete, con las confluencias del Vergara, el Duqueco y el Bureo. Primero mira **una imagen** de cada satélite casi el mismo día; después construye la **serie temporal** de cada uno en 9 puntos del río (el thalweg de secciones de un modelo hidráulico 1D); luego los **compara** en los días en que pasaron los dos, **explora** las series y busca **anomalías y eventos extremos**.

Es un híbrido de los bloques 03, 04, 05 y 07 del taller *Datos FAIR, series temporales satelitales y detección de anomalías con Python* (curso Geomática Aplicada, repositorio alvaroparedesl/geomatica-aplicada). Usa las funciones de apoyo del curso (carpeta *utils/*) y el mismo **patrón nativo**: la búsqueda (`pystac_client`) y la carga (`odc.stac.load`) son llamadas nativas; los helpers solo preparan sus argumentos.



Los dos satélites en una tabla

	Sentinel-2 L2A (ESA)	Landsat 8 y 9 C2 L2 (USGS)
Tamaño de píxel	10 m (visible y NIR), 20 m (SWIR)	30 m (ópticas), 100 m (térmica, entregada a 30 m)
Revisita	2 a 5 días (2 o 3 satélites)	8 días (2 satélites)
Historia	desde 2015-2017	desde 2013 (Landsat 8)
Banda térmica	no	sí: temperatura de superficie
De número digital (DN) a reflectancia	DN × 0,0001 + offset (0 o -0,1 según el baseline de cada imagen)	DN × 0,0000275 - 0,2
Máscara de nubes	banda SCL (una clase por píxel)	banda qa_pixel (un bit por condición)

Datos: ESA Copernicus Sentinel-2 L2A (contiene datos Copernicus Sentinel modificados) y USGS Landsat 8/9 Collection 2 Level-2, leídos desde Microsoft Planetary Computer. Métodos y funciones de apoyo: curso Geomática Aplicada (alvaroparedesl/geomatica-aplicada, GPL-3.0).

Bloque 0. Entorno, parámetros y puntos

todos los bloques del taller

Objetivo. Dejar listo todo lo que usan los bloques siguientes, en Colab o en un computador.

Qué hace el código

1. **Preparar entorno.** Descarga el repositorio del curso para usar su carpeta `utils/`, fijado en una versión exacta (`COMMIT_CURSO`): si el curso cambia una función, el notebook sigue funcionando.
2. **Instalar paquetes.** Solo si faltan: `pystac-client`, `planetary-computer`, `odc-stac` y `rioxarray`.
3. **Importar** las bibliotecas y las funciones del curso que se usan (STAC, raster, series y extremos).
4. **Parámetros**: todo lo que se puede cambiar está en una sola celda (tabla de abajo).
5. **Puntos.** Lee el CSV de 9 puntos con `cargar_puntos_csv` (valida columnas y coordenadas), calcula el sistema de coordenadas UTM 18 S y la **ventana de trabajo**: los puntos con 2 km de holgura, unos 44 × 22 km. Dibuja un mapa interactivo con los puntos y la ventana.
6. **Funciones propias**, cortas y a la vista: `BANDAS` traduce los nombres de banda de cada satélite a nombres comunes (verde, rojo, NIR, SWIR1), `indices_comunes` calcula los mismos índices con los dos y `lado_a_lado` dibuja una variable de los dos satélites en la misma escala.

Parámetros principales

Parámetro	Valor	Para qué
`FECHAS_ESCENA`	ene-mar 2025	dónde buscar el par de imágenes del bloque A (verano: menos nubes)
`FECHAS_S2`	2024-2025	período de la serie Sentinel-2
`FECHAS_LANDSAT`	2013-2025	período de la serie Landsat (permite climatología de varios años)
`NUBES_MAX_SERIES`	70 %	filtro de escena laxo; la máscara de cada píxel hace el resto
`RADIO_M`	45 m	ventana alrededor de cada punto: unos 20 píxeles de Sentinel-2 y 7 de Landsat
`FRACCION_MINIMA`	0,5	una fecha vale si al menos la mitad de la ventana quedó sin nubes
`EJECUTAR_EXTREMOS`	True	activa el bloque E (opcional)
`USAR_DRIVE`	True	en Colab guarda los archivos en Google Drive: no se pierden al cerrar la sesión
`RECALCULAR`	False	True obliga a descargar de nuevo aunque los archivos ya existan

Los datos del satélite se descargan una sola vez. Las series quedan en archivos .parquet (uno por satélite y por año) y las dos escenas del bloque A en un .npz comprimido. Al volver a ejecutar, el notebook lee esos archivos y no descarga nada: los bloques C, D y E trabajan solo con los parquet. En Colab los archivos van a Google Drive (la carpeta /content se borra al cerrar la sesión).

Para la presentación: el radio de 45 m es pequeño a propósito. Los afluentes miden 30 a 60 m de ancho; una ventana grande mezclaría el agua con la ribera. Con este radio la diferencia de resolución entre los dos satélites se nota justamente en los afluentes.

Bloque A. Una imagen de cada satélite

basado en el bloque 03

Objetivo. Ver el mismo río con los dos satélites casi el mismo día y entender en qué se diferencian sus píxeles.

Qué hace el código

1. **A.1 Buscar un par.** Busca las colecciones `sentinel-2-l2a` y `landsat-c2-l2` de Planetary Computer sobre la ventana de trabajo, en verano y con menos de 10 % de nubes (`catalogo.search`). `preparar_items` quita las versiones repetidas de Sentinel-2. Arma una tabla de pares de días y elige el de menos días entre ambas imágenes y menos nubes. Los dos satélites pasan cerca de las 14:40 UTC, así que hay días en que pasan los dos.
2. **A.2 Cargar y calibrar.** `parametros_carga` + `odc.stac.load` leen solo la ventana (formato COG: no se descarga la escena completa). Sentinel-2 a 10 m, Landsat a 30 m. Se pasa de números digitales a reflectancia con la fórmula de cada satélite; en Sentinel-2 el offset sale del baseline de cada imagen (`agregar_offset`). La banda térmica de Landsat se convierte a °C: DN × 0,00341802 + 149 - 273,15.
3. **Guardar las escenas.** Las dos escenas quedan en un .npz comprimido (números digitales sin calibrar). Si el archivo ya existe, A.1 y A.2 lo leen y no buscan ni descargan nada.
4. **A.3 Color verdadero y falso color** (NIR, rojo, verde), lado a lado.
5. **A.4 Índices**: NDWI (agua), MNDWI (agua con sedimento), NDVI (vegetación) y la reflectancia roja solo sobre el agua (turbidez), lado a lado y con la misma escala de colores.
6. **A.5 Temperatura de superficie**: el mapa que solo Landsat puede hacer. Compara la temperatura mediana del agua con la de la tierra.
7. **A.6 Zoom** de 3 × 3 km en la confluencia del Vergara: 10 m frente a 30 m.
8. **A.7 Cuánta agua ve cada satélite**: área con MNDWI > 0 e histograma del NDWI.
9. **A.8 Valor del píxel en cada punto** con los dos satélites (`.sel(x, y, method=nearest)`).

Qué mostrar y qué decir

- La misma zona tiene unas **9 veces más píxeles** en Sentinel-2 (10 m frente a 30 m).
- En el Biobío (cientos de metros de ancho) los dos satélites ven casi lo mismo. En un afluente de 50 m, Sentinel-2 tiene unos 5 píxeles a lo ancho y Landsat 1 o 2 **píxeles mixtos** (agua y orilla a la vez): su NDWI baja.
- Landsat tiene más píxeles mixtos: su histograma de NDWI se "rellena" entre el grupo del agua y el de la tierra.
- Solo Landsat mide **temperatura**: en verano el río es mucho más frío que los campos y barras que lo rodean.

Concepto clave: un número digital (DN) no es reflectancia. Si se olvida el offset de Sentinel-2 o el -0,2 de Landsat, el agua da valores absurdos (bloque 02 y 07 del taller). Por eso el offset nunca se fija a mano.

Bloque B. Series temporales con los dos satélites

basado en el bloque 04

Objetivo. Pasar de una imagen a una serie: el valor de cada punto, fecha tras fecha, con cada satélite.

Qué hace el código

1. **Serie año por año** (`serie_por_anios`): para cada año busca las imágenes, descarta las que tienen archivos dañados (`items_legibles`), carga una **ventana pequeña** alrededor de cada punto y la resume. Cada año queda en un parquet (`serie_s2_AAAA_r45m.parquet`, con el radio en el nombre). Si el archivo ya existe se lee y no se descarga nada; solo se baja lo que falta.
2. **Sentinel-2**: `cargar_ventanas` + `construir_series` del curso. Máscara de nubes con la banda SCL, reflectancia con el offset de cada fecha, índices NDWI, NDCI, NDVI y la reflectancia roja B04.
3. **Landsat**: `cargar_ventanas_landsat` + `construir_series_landsat`. Máscara con qa_pixel y qa_radsat, calibración de temperatura y reflectancia, NDWI y NDVI.
4. **Resumen de cada fecha**: la mediana de los píxeles válidos a 45 m o menos del punto. Si menos de la mitad de la ventana quedó sin nubes, la fecha se conserva con los valores en NaN (para que se vea el vacío).
5. **B.1 Validez**: `resumen_validez` cuenta las fechas útiles por punto, y un gráfico de barras compara las observaciones sin nubes por año de cada satélite.
6. **B.2 Parquet con metadatos (FAIR)**: `guardar_series` guarda cada serie con título, fuente, licencia, parámetros y el significado de cada columna dentro del mismo archivo.
7. **B.3 Gráfico interactivo** (plotly) de NDWI, NDVI y turbidez de un punto con los dos satélites.

Columnas de cada serie

Satélite	Variables por punto y fecha
Sentinel-2	`ndwi`, `ndci` (clorofila), `b04` (rojo, turbidez), `ndvi`, `pixeles_validos`, `nubes_escena`, `offset_reflectancia`
Landsat	`st_c` (temperatura, °C), `verde`, `rojo`, `nir`, `swir1`, `ndwi`, `ndvi`, `pixeles_validos`, `nubes_escena`, `plataforma`

Para la presentación: cargar ventanas pequeñas en vez de toda la zona es lo que hace posible la serie en un notebook (cientos de MB en vez de decenas de GB). El filtro de nubes de la escena es barato pero ciego al punto; la máscara de cada píxel es la que protege la serie. Se usan las dos.

Bloque C. Comparación directa el mismo día

nuevo

Objetivo. Medir cuánto se parecen los dos satélites cuando miran el mismo río el mismo día.

Qué hace el código

1. Junta las dos series por punto y por **día**: quedan solo las fechas en que pasaron los dos.
2. Para NDWI, NDVI y reflectancia roja calcula el **sesgo** (media de Landsat - Sentinel-2), el **RMSE** (error cuadrático medio) y la correlación **r** de Pearson.
3. Dibuja un gráfico de dispersión por variable, con la línea 1:1 y un símbolo por tipo de punto (río, confluencia, afluente).
4. Calcula la diferencia de NDWI por punto para ver si es mayor en los afluentes angostos.

Qué mostrar y qué decir

- En el cauce principal los puntos caen cerca de la línea 1:1: los dos satélites **se pueden combinar** para tener más fechas.
- En los afluentes, el NDWI de Landsat queda por debajo: el píxel de 30 m mezcla agua y ribera. Para ríos angostos, Sentinel-2.
- Comparar el mismo día elimina las diferencias del río (caudal, turbidez): lo que queda es la diferencia del sensor.

Bloque D. Exploración, climatología y anomalías

basado en el bloque 05

Objetivo. Mirar las series con números: valores típicos, ritmo estacional, tendencia y valores raros.

Qué hace el código

1. **D.1 Estadísticos** por punto y satélite (n, media, mediana, p10, p90, máximo) de la turbidez, y cajas lado a lado de aguas arriba a aguas abajo.
2. **D.2 Media móvil en días**: 30 días para Sentinel-2 y 60 para Landsat, con un mínimo de 3 observaciones. Con fechas irregulares la ventana se mide en días, no en número de observaciones.
3. **D.3 Ciclo anual**: mediana mensual por punto (mapas de calor) de la turbidez con cada satélite y de la temperatura del río con Landsat.
4. **D.4 Tendencia** (`tendencia_lineal`): con la serie larga de Landsat se quita primero el ciclo anual (anomalía respecto de la media de cada mes) y se ajusta una recta a las anomalías: cambio por década.
5. **D.5 Anomalías z-score** (`anomalias_zscore`): z = (valor - media) / desviación. Sentinel-2, con pocos años, usa la referencia de toda la serie; Landsat usa la del mismo mes de todos los años, que quita la estación. Gráfico de la anomalía mensual de la temperatura del río.

Para la presentación: con un año de datos una pendiente mezcla la estación con el cambio (bloque 05). La serie larga de Landsat es la que permite hablar de tendencia y de anomalías respecto del mismo mes. El valor p supone observaciones independientes y sobreestima la significancia. Un mes sin barra es un mes **sin dato**, no una anomalía cero.

Bloque E. Eventos extremos (opcional)

basado en el bloque 07

Objetivo. Distinguir una anomalía (un valor raro) de un episodio (una anomalía que persiste), y confirmarlo con los dos satélites.

Qué hace el código

1. **Control de calidad** (`controlar_calidad_agua`): la reflectancia delata las nubes que la máscara no vio. El curso usa rojo < 0,05 y SWIR1 < 0,02 para agua de mar clara; un río turbio refleja más rojo, así que se relaja a rojo < 0,30 y SWIR1 < 0,05.
2. **Climatología por ventana de días** (`climatologia_ventana`): para cada día del año, la media y los percentiles 10 y 90 de las observaciones de todos los años a ±15 días (idea de Hobday, adaptada a series irregulares).
3. **E.1 Episodios de temperatura** (Landsat, `detectar_episodios`): al menos 2 observaciones seguidas sobre el p90 (cálido) o bajo el p10 (frío), sin huecos de más de 24 días.
4. **E.2 Episodios de turbidez alta** con los dos satélites (posibles crecidas). Sentinel-2 tiene pocos años, así que cada año se compara con **los otros años** (ventana de ±30 días) para que una crecida no infle su propia referencia; huecos de hasta 12 días. Luego cuenta cuántos episodios de Sentinel-2 también ve Landsat (±5 días).
5. **E.3 Isolation Forest** (`aislamiento_forest_observaciones`): aprendizaje automático que marca combinaciones raras de temperatura, turbidez y NDWI a la vez. Se compara con el umbral clásico con el índice de Jaccard (en común / unión).
6. Guarda los episodios en `salidas/` (CSV).

Umbral clásico frente a aprendizaje automático

	Umbral p10-p90 por día del año	Isolation Forest
Pregunta	¿supera lo que pasa el 10 % de las veces en esta época?	¿es rara esta combinación de variables?
Estación	integrada (un umbral por día del año)	hay que quitarla antes (anomalías)
Duración	regla explícita (observaciones seguidas, brecha)	marca observaciones sueltas
Varias variables	una a la vez	sí
Explicación	"2 observaciones seguidas sobre el p90"	"su puntaje de aislamiento fue bajo"

Para la presentación: un episodio que aparece **con los dos satélites** a la vez es mucho más creíble que uno solo: así se distingue una anomalía real (una crecida, una ola de calor en el río) de un error del sensor. Con 8 a 16 días entre pasadas, la duración de un episodio es solo una cota mínima y la tabla subestima la frecuencia.

Cierre: qué aporta cada satélite

Pregunta	Mejor satélite	Por qué
Ríos angostos (afluentes de 30 a 60 m)	Sentinel-2	píxel de 10 m; en Landsat el píxel mezcla agua y orilla
Muchas fechas en un período corto	Sentinel-2	revisita de 2 a 5 días
Climatología, tendencia y anomalías de varios años	Landsat	serie desde 2013
Temperatura del agua	Landsat	única con banda térmica
Turbidez en el Biobío principal	los dos	coinciden el mismo día: se pueden combinar
Confirmar un evento extremo	los dos	un episodio visto por ambos es más creíble

Límites que conviene decir

- Solo hay datos con cielo despejado: las crecidas en días de lluvia quedan tapadas por nubes.
- La reflectancia roja es un **indicador** de turbidez, no una concentración: sin muestras en terreno no hay mg/L.
- La temperatura de Landsat es la de la piel del agua, con un error de 1 K o más.
- Con 2 años de Sentinel-2 su climatología es corta; para más confianza, alargar FECHAS_S2 (toma más tiempo).

Archivos que genera

Archivo	Contenido
`salidas/serie_s2_AAAA_r45m.parquet`	serie Sentinel-2 de cada año (se lee en vez de descargar)
`salidas/serie_landsat_AAAA_r45m.parquet`	serie Landsat de cada año
`salidas/escenas_bloque_A_....npz`	las dos escenas del bloque A (números digitales)
`salidas/series_sentinel2_biobio.parquet`	serie Sentinel-2 completa, con metadatos
`salidas/series_landsat_biobio.parquet`	serie Landsat completa, con metadatos
`salidas/series_<punto>.html`	gráfico interactivo de un punto con los dos satélites
`salidas/episodios_*.csv`	episodios de temperatura y de turbidez (bloque E)

Glosario rápido

Término	Significado
STAC	estándar de catálogos de imágenes: se busca por metadatos (zona, fecha, nubes) sin descargar nada
COG	GeoTIFF optimizado para la nube: se puede leer solo una parte de la imagen
DN, offset, baseline	número digital guardado en el archivo; la corrección que lo pasa a reflectancia; la versión del procesador de la ESA que decide el offset de Sentinel-2
SCL / qa_pixel	bandas de calidad que marcan nubes, sombras y sin dato (Sentinel-2 / Landsat)
NDWI / MNDWI / NDVI	índices de agua (verde-NIR / verde-SWIR1) y de vegetación (NIR-rojo)
z-score	cuántas desviaciones estándar se aleja un valor de lo normal
p90 / p10	percentiles: el valor bajo el cual queda el 90 % (o el 10 %) de las observaciones
Episodio	al menos 2 observaciones seguidas fuera del rango p10-p90, sin cruzar huecos largos
Isolation Forest	método de aprendizaje automático que aísla las observaciones raras con cortes al azar
Jaccard	observaciones en común dividido por observaciones de la unión (0 a 1)